

INTRODUÇÃO À ECONOMETRIA SEMIPARAMÉTRICA

AULA 1 - ESTIMAÇÃO NÃO PARAMÉTRICA MODERNA

Luis A. F. Alvarez

4 de outubro de 2024

ESTIMANDO UMA DENSIDADE

- Suponha que você, pesquisador, possui uma amostra aleatória $\{X_i\}_{i=1}^n$ de uma distribuição contínua F , cuja densidade denotamos por f .
 - Por exemplo, você possui dados da riqueza não financeira de uma amostra de indivíduos.
- Você está interessado em estimar a densidade f .
- Como você pode fazer isso?

ESTIMAÇÃO PARAMÉTRICA

- Um caminho consiste em realizar uma hipótese de forma funcional acerca de f .
- Por exemplo, se nossa população de interesse está restrita à cauda superior da distribuição de riqueza, a literatura sugere que deve valer a “lei de Pareto” (Benhabib e Bisin, 2018), segundo a qual:

$$f(x) = g(x|x_0, \alpha) = \alpha \frac{x_0^\alpha}{x^{\alpha+1}} \mathbf{1}\{x \geq x_0\}, \quad x_0, \alpha > 0$$

- Distribuição compatível com modelos de agentes heterogêneos com mercados incompletos e ativos arriscados (Achdou et al., 2022).
- Sob a hipótese de forma funcional, a estimação de f se resume à estimação de dois parâmetros, $(x_0, \alpha) \in \mathbb{R}^2$.
- Por exemplo, podemos estimá-los através de máxima verossimilhança:

$$(\hat{x}_0, \hat{\alpha}) \in \operatorname{argmax}_{(z,a) \in \mathbb{R}^2} \frac{1}{n} \sum_{i=1}^n \log g(X_i|z, a)$$

FORMA FUNCIONAL E ESTIMAÇÃO NÃO PARAMÉTRICA

- E se a lei de Pareto não for válida?
 - Nesse caso, a densidade estimada não recuperará a distribuição correta, mesmo em amostras grandes.
- Como podemos estimar a distribuição correta sem requerer a hipótese de forma funcional?
- Para isso, necessitamos de métodos **não paramétricos**, que dispensem da hipótese de forma funcional.

HISTOGRAMA

- O estimador não paramétrico mais simples é o histograma.
- Em um histograma, o suporte da distribuição é dividido em J células (*bins*) de comprimento $2h$, e a densidade para os pontos na j -ésima célula, $[a_j, b_j)$, é estimada como constante igual a:

$$\hat{f}_h(x_j) = \frac{1}{n2h} \sum_{i=1}^n \mathbf{1}\{|X_i - x_j| \leq h\} ,$$

onde o $x_j = \frac{a_j+b_j}{2}$ é o ponto intermediário da célula j .

ESTIMADOR DE *KERNEL* PARA DENSIDADE

- O estimador $\hat{f}_h(x_j)$ usado na construção do histograma é um caso particular de um *estimador de kernel* para uma densidade em um ponto x , que é dado por:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{j=1}^n K\left(\frac{X_j - x}{h}\right),$$

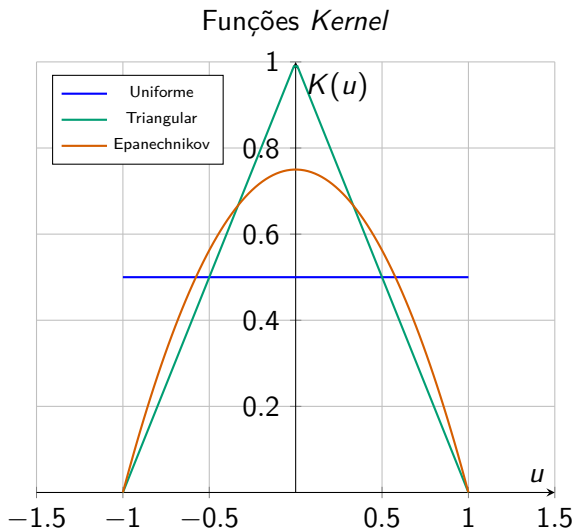
onde $K : \mathbb{R} \mapsto \mathbb{R}$ é um *kernel*, i.e. uma função satisfazendo $\int_{-\infty}^{\infty} K(u)du = 1$ e simétrica em torno do zero, $K(u) = K(-u)$.

- No que segue, vamos supor que K é uma função não negativa com suporte no intervalo $[-1, 1]$, embora essas hipóteses não sejam necessárias para a maioria dos resultados.
- Sob a hipótese anterior, estimador de *kernel* propõe estimar $f(x)$ “contando” os pontos da amostra com distância a menos de h de x . K nos dá então o peso relativo de cada ponto dentro de essa região.

EXEMPLOS DE *KERNEL*

<i>Kernel</i>	Fórmula
Uniforme	$K(u) = \frac{1}{2} \cdot \mathbf{1}(u \leq 1)$
Triangular	$K(u) = (1 - u) \cdot \mathbf{1}(u \leq 1)$
Epanechnikov	$K(u) = \frac{3}{4}(1 - u^2) \cdot \mathbf{1}(u \leq 1)$

EXEMPLOS DE *KERNEL*



CALCULANDO O VIÉS DO ESTIMADOR DE *KERNEL*

- Vamos analisar as propriedades estatísticas do estimador de *kernel*.
- Considere um ponto x do suporte da distribuição tal que $f(\cdot)$ seja duas vezes continuamente diferenciável numa vizinhança de x . Neste caso, temos que, à medida que $h \rightarrow 0$:

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &= \frac{1}{nh} \sum_{i=1}^n \mathbb{E} \left[K \left(\frac{X_i - x}{h} \right) \right] = \frac{1}{h} \mathbb{E} \left[K \left(\frac{X_1 - x}{h} \right) \right] = \\ &= \frac{1}{h} \int_{x-h}^{x+h} K \left(\frac{s-x}{h} \right) f(s) ds \stackrel{u=\frac{s-x}{h}}{=} \int_{-1}^1 K(u) f(x+hu) du = \\ &= f(x) \underbrace{\int_{-1}^1 K(u) du}_{=1} + f'(x)h \underbrace{\int_{-1}^1 uK(u) du}_{=0} + \int_{-1}^1 (uh)^2 f''(\tilde{x}_{hu}) K(u) du = \\ &= f(x) + h^2 f''(x) \int_{-1}^1 u^2 K(u) du + o(h^2)\end{aligned}$$

onde, da segunda para a terceira linha, aplicamos o teorema do valor médio de segunda ordem, e a última passagem usa continuidade (uniforme) da segunda derivada numa vizinhança de x .

CALCULANDO A VARIÂNCIA DO ESTIMADOR DE *KERNEL*

- Do mesmo modo:

$$\mathbb{V}[\hat{f}_h(x)] = \frac{1}{nh^2} \mathbb{V} \left[K \left(\frac{X_1 - x}{h} \right) \right]$$

- Mas:

$$\mathbb{E} \left[K \left(\frac{X_1 - x}{h} \right)^2 \right] = h \int_{-1}^1 f(x) K^2(u) du + O(h^3)$$

e

$$\mathbb{E} \left[K \left(\frac{X_1 - x}{h} \right) \right]^2 = h^2 f(x)^2 + O(h^3)$$

- De modo que:

$$\mathbb{V}[\hat{f}_h(x)] = \frac{1}{nh} \int_{-1}^1 f(x) K^2(u) du + \frac{1}{n} f(x)^2 + O\left(\frac{h}{n}\right)$$

ERRO QUADRÁTICO MÉDIO DO ESTIMADOR DE KERNEL

- Combinando os pontos anteriores, temos que:

$$\begin{aligned} \text{EQM}[\hat{f}_h(x)] &= \mathbb{E}[(\hat{f}_h(x) - f(x))^2] = \\ &= h^4 f''(x)^2 \left(\int_{-1}^1 u^2 K(u) du \right)^2 + \frac{1}{nh} \int_{-1}^1 f(x) K^2(u) du + \frac{1}{n} f(x)^2 + o(1) \end{aligned}$$

- Portanto, se $n \rightarrow \infty$ com $h \rightarrow 0$ e $nh \rightarrow \infty$.

$$\text{EQM}[\hat{f}_h(x)] \rightarrow 0,$$

e o estimador de kernel é *consistente*.

- Além disso, da expressão acima escolha h ótima, que balanceia *trade-off* viés-variância, é dada por:

$$h \propto n^{-1/5}$$

ESTIMAÇÃO DE DENSIDADES MULTIDIMENSIONAIS

- O estimador anteriormente introduzido é facilmente extensível para a estimação de uma densidade em \mathbb{R}^d . Seja \mathbf{f} uma densidade em \mathbb{R}^d , e $\{\mathbf{X}_i\}_{i=1}^n$ uma amostra aleatória desta distribuição. Podemos estimar $\mathbf{f}(\mathbf{x})$ como:

$$\hat{\mathbf{f}}_{\mathbf{h}}(\mathbf{x}) = \frac{1}{nh_1 \dots h_d} \sum_{i=1}^n \mathbf{K}_{\mathbf{h}}(\mathbf{X}_i - \mathbf{x})$$

onde $\mathbf{K}_{\mathbf{h}}(\mathbf{u}) = \prod_{j=1}^d K(u_j/h_j)$, com K um *kernel* univariado.

- Nesse caso, viés é proporcional da ordem de $d \max_j h_j^2$ e variância a $\frac{1}{nh_1 \dots h_d}$. Portanto, se:

$$\max_j h_j \rightarrow 0, \quad nh_1 \dots h_d \rightarrow \infty,$$

estimador é consistente.

ESTIMADOR DE NADARAYA-WATSON PARA A ESPERANÇA CONDICIONAL

BIBLIOGRAFIA I



Achdou, Yves et al. (2022). “Income and wealth distribution in macroeconomics: A continuous-time approach”. *Em: The review of economic studies* 89.1, pp. 45–86.



Benhabib, Jess e Alberto Bisin (2018). “Skewed wealth distributions: Theory and empirics”. *Em: Journal of Economic Literature* 56.4, pp. 1261–1291.